

SpeedDating - Clustering

Sadržaj

1. Analiza početnih podataka

- 1.1 Poreklo i osnovna struktura skupa
- 1.2 Jedinica posmatranja
- 1.3 Nedostatak identifikatora učesnika i njegova rekonstrukcija
- 1.4 Struktura atributa
- 1.5 Nedostajuće vrednosti
- 1.6 Redundantnost atributa
- 1.7 Kršenja domenskih pravila
- 1.8 Ciljni atribut

2. Preprocesiranje

- 2.1 Uklanjanje atributa
- 2.2 Ispravke po domenskim pravilima
- 2.3 Obrada tekstualnog atributa `field`
- 2.4 Da li su nedostajuće vrednosti slučajne? (MNAR analiza)
- 2.5 Kategorijske praznine
- 2.6 Enkodiranje kategorijskih atributa
- 2.7 Blok-normalizacija
- 2.8 Imputacija, korak 1: oporavak unutar iste osobe
- 2.9 Imputacija, korak 2: kNN
- 2.10 Dva skupa i curenje informacije kroz imputaciju
- 2.11 Izlazni fajlovi

3. Klasterovanje

- 3.1 Metodološki okvir
- 3.2 Skup 1: profil osobe
- 3.3 Skup 2: preference i samoprocena
- 3.4 Poređenje pet algoritama
- 3.5 Skup 3: interesovanja
- 3.6 Skup 4: pun skup atributa

4. Tumačenje i zaključci

- 4.1 Šta su klasteri otkrili
- 4.2 Metodološke pouke
- 4.3 Ograničenja

1. Analiza početnih podataka

1.1 Poreklo i osnovna struktura skupa

Skup podataka *Speed Dating Experiment* preuzet je sa platforme OpenML (ID 40536) pomoću funkcije `fetch_openml`, čime je preuzimanje automatizovano i ponovljivo, nije korišćen ručno preuzet fajl, pa svako ko pokrene notebook dobija identičan polazni skup.

Skup sadrži **8378 slogova** i **121 atribut**, (2000 slogova, 100 atributa). Podaci potiču iz eksperimenta sprovedenog na Univerzitetu Kolumbija, u kojem su učesnici imali niz četvorominutnih susreta, nakon svakog popunjavali kratak upitnik o partneru, i na kraju označavali sa kim bi želeli ponovni kontakt.

Po tipovima, sirovi skup čini 57 numeričkih, 62 kategorijska i 2 celobrojna atributa. Kao što će biti pokazano u odeljku 1.6, veliku količinu kategorijskih atributa čine kopije numeričkih atributa.

1.2 Jedinica posmatranja

Svaki red je jedan sastanak, a ne jedna osoba. Precizno: jedan četvorominutni susret, opisan iz perspektive jednog od dvoje učesnika. Pošto je svaki učesnik tokom večeri imao između 5 i 22 sastanka, ista osoba se pojavljuje u više redova. U svim tim redovima njeni lični atributi, hobiji, deklarisanе preference, samoprocene, **su identični**, dok se menjaju samo atributi koji opisuju partnera i sam susret.

Odluka: klasterujemo sastanke, uz zadržavanje svih 8378 slogova

Alternativa je bila agregirati podatke na nivo osobe (549 redova), ali bi to prekršilo uslov od najmanje 2000 slogova i, što je važnije, odbacilo bi sve informacije o samom susretu. Posledica prihvaćene odluke je da učesnici sa više sastanaka nose proporcionalno veću težinu u klasterovanju. Kao kontrola, rekonstruisani identifikator `person_id` sačuvan je u `metadata.csv`, čime je omogućena naknadna provera na nivou osobe.

1.3 Nedostatak identifikatora učesnika i njegova rekonstrukcija

Originalni Columbia skup sadrži atribut `iid` jedinstveni identifikator učesnika, koji omogućava trivijalno grupisanje redova po osobi. **OpenML verzija taj atribut ne sadrži**; izbačen je pri pripremi skupa za platformu. To je praktičan problem: bez njega se ne zna koji redovi pripadaju istoj osobi, pa nije moguće ni proveriti doslednost, ni pametno popuniti praznine.

Identifikator je stoga **rekonstruisan**. Ideja je jednostavna: ista osoba, u istom talasu događaja, mora imati identične vrednosti svih nepromenljivih atributa. Kao ključ je iskorišćena kombinacija: godine, pol, sve indikatorske kolone rase, sve indikatorske kolone oblasti studija, i svih šest deklarisanih preferenci. Redovi sa identičnim ključem u istom talasu proglašeni su istom osobom.

Postupak je dao **549 učesnika** kroz 8378 redova, sa 5 do 22 sastanka po osobi (medijana 16). Ovo je heuristika, pa je odmah i proverena: za svakog rekonstruisanog učesnika izbrojan je broj različitih vrednosti koje njegovi redovi imaju po atributima na nivou osobe. Ako bi ključ slučajno spojio dvoje ljudi, oni bi se razlikovali makar po jednom hobiju ili samoproceni. Rezultat provere: **0 nedoslednih od 549** te nijedan identitet nije pogrešno spojen.

1.4 Struktura atributa

Atributi se prirodno grupišu u nekoliko pojmovnih celina, što je kasnije iskorišćeno pri normalizaciji:

Celina	Primeri atributa	Šta opisuje
Interesovanja (17)	<code>sports</code> , <code>art</code> , <code>museums</code> , <code>yoga</code>	osobu
Deklarisane preference (6)	<code>attractive_important</code> , <code>ambtition_important</code>	osobu
Samoprocene (5)	<code>attractive</code> , <code>intelligence</code> , <code>ambition</code>	osobu
Preference partnera (6)	<code>pref_o_attractive</code> , <code>pref_o_funny</code>	partnera
Ocene partnera (6)	<code>attractive_partner</code> , <code>funny_partner</code>	susret
Ocene od partnera (6)	<code>attractive_o</code> , <code>funny_o</code>	susret
Demografija (3)	<code>age</code> , <code>age_o</code> , <code>d_age</code>	osobu / par
Ishod (2)	<code>like</code> , <code>guess_prob_liked</code>	susret
Ostalo	<code>met</code> , <code>samerace</code> , <code>interests_correlate</code>	par

Ova podela na attribute koji opisuju *osobu*, *partnera*, *par* i *susret* nije formalna. Ona je direktno određivala koji su atributi ulazili u koji model klasterovanja i kako je imputacija sprovedena.

1.5 Nedostajuće vrednosti

Skup sadrži **18372 nedostajuće vrednosti raspoređene po 60 kolona**. Raspodela nije ravnomerna, i sama po sebi govori o tome kako je anketa popunjavana:

Atribut	Nedostaje	Udeo	Priroda
expected_num_interested_in_me	6578	79%	pitanje postavljano samo u nekim talasima
expected_num_matches	1173	14%	očekivanja pred događaj
shared_interests_o	1076	13%	ocena koja traži dublje poznanstvo
shared_interests_partner	1067	13%	ocena koja traži dublje poznanstvo
met	375	4.5%	pitanje o ranijem poznanstvu
attractive_partner	202	2.4%	ocena koja se daje trenutno
17 hobija (svaki)	79	0.9%	ceo blok preskočen

Dva obrasca se odmah vide. Prvo, atribut `expected_num_interested_in_me` prazan je u 79% slučajeva, imputacija pri toj stopi bila bi izmišljanje, ne procena. Drugo, svih 17 hobija ima **tačno istih 79 praznina**, što znači da 79 učesnika nije popunilo ceo blok pitanja o interesovanjima. Praznine dolaze u blokovima, ne pojedinačno, to je nalaz koji je kasnije odredio strategiju imputacije.

1.6 Redundantnost atributa

Od 121 atributa, **56 su diskretizovane kopije** numeričkih. Na primer, uz numerički `attractive` (vrednosti 1–10) postoji i kategorijski `d_attractive` sa vrednostima poput `[6–8]`. Diskretizovana verzija nosi strogo manje informacija od numeričke, pa je zadržana numerička.

`d_age` nije diskretizovana kopija

Naivni filter „izbaci sve kolone koje počinju sa `d_`” izbacio bi i `d_age`. Međutim, `d_age` je **razlika u godinama između partnera**, pravi, koristan atribut. Njegova diskretizovana verzija zove se `d_d_age`. Filter je stoga eksplicitno izuzeo `d_age`, čime je broj uklonjenih kolona 55, a ne 56.

1.7 Kršenja domenskih pravila

Anketa nameće pravila koja sirovi podaci ponegde krše. Provera je sprovedena eksplicitno, umesto oslanjanja na pretpostavku da su podaci ispravni:

Pravilo	Prekršaja	Detalj
Težine preferenci se sabiraju na 100	144	maksimalan zbir 148
Interesovanja u opsegu [1, 10]	350	ćelija van opsega
Ocene u opsegu [1, 10]	259	ćelija van opsega
<code>met</code> je binaran	8	vrednosti 3, 5, 7
Starost — IQR pravilo	173	outlieri (nisu greška)

1.8 Ciljni atribut

Atribut `match` označava da li je došlo do obostranog interesovanja. Raspodela je neuravnotežena: **1380 poklapanja naspram 6998 nepoklapanja**, odnosno stopa od **0.165**.

Iako je zadatak nenadgledan, ovaj atribut ima ključnu ulogu, ne kao ulaz, već kao **nezavisna provera**. Ako klasteri dobijeni bez ikakvog znanja o ishodu ipak pokažu različite stope poklapanja, to znači da su uhvatili nešto stvarno. Da bi ta provera bila poštena, `match` je izdvojen u `metadata.csv` i nijednom nije korišćen pri klasterovanju.

2. Preprocesiranje

Preprocesiranje je sprovedeno u devet koraka, redom: uklanjanje atributa, ispravke po domenskim pravilima, obrada tekstualne kolone, analiza prirode nedostajućih vrednosti, tretman kategorijskih praznina, enkodiranje, blok-normalizacija, dvostepena imputacija i čuvanje rezultata. Svaki korak je obrazložen posebno, jer je u većini slučajeva postojala i alternativa koja je odbačena.

2.1 Uklanjanje atributa

Uklonjeno je ukupno 58 kolona, iz tri različita razloga.

55 diskretizovanih duplikata

Kao što je objašnjeno u odeljku 1.6, ove kolone su višak. Zadržane su numeričke. `has_null` je eksplicitno sačuvan.

`has_null`

Meta-atribut koji označava da li slog sadrži neku prazninu. On opisuje *kvalitet zapisa*, ne osobu. Klasterovanje po njemu proizvelo bi grupu „nepotpuni slogovi“, što nije tip ličnosti nego artefakt ankete.

`expected_num_interested_in_me`

79% praznina. Popuniti četiri petine kolone značilo bi da je gotovo cela kolona naša konstrukcija, a ne merenje.

`wave` — *administrativni identifikator sesije*

Talas (1–21) označava koje večeri je događaj održan.

Problem je što se talasi drastično razlikuju po veličini, od 50 do 968 učesnika. Da je `wave` ostao kao atribut, algoritam bi lako mogao da nađe klastere koji odgovaraju *rasporedu događaja*, a ne tipovima ljudi. Takav klaster bio bi savršeno „čvrst“ po metrikama, a potpuno beskoristan po smislu.

Ipak, `wave` je sačuvan u `metadata.csv`, upravo da bi se moglo proveriti da se dobijeni klasteri *slučajno* ne poklapaju sa sesijama.

Posle ovog koraka skup ima oblik 8378×63 .

2.2 Ispravke po domenskim pravilima

Za svako otkriveno kršenje (odeljak 1.7) doneta je posebna odluka.

Težine preferenci — renormalizacija umesto odbacivanja

Učesnik je trebalo da raspodeli tačno 100 poena na šest osobina. 144 sloga se sabira na nešto drugo (do 148). Umesto brisanja tih slogova ili njihovog označavanja kao neispravnih, težine su **renormalizovane** (svaka podeljena zbirom i pomnožena sa 100).

Obrazloženje: učesnik koji je upisao 40/30/30/20/15/13 (zbir 148) jasno je izrazio *relativne* prioritete; greška je samo u aritmetici. Renormalizacija čuva ono što je rekao, a ispravlja ono što je pogrešio.

Ocene i interesovanja — odsecanje na [1, 10]

Vrednost 12 na skali 1–10 najverovatnije znači „maksimalno“, pa je 10 verniji prevod od brisanja.

`met` — *binarizacija*

Osam slogova sadrži vrednosti 3, 5, 7 na pitanju koje bi trebalo da bude da/ne. Verovatno je učesnik upisao *koliko puta* se sreo sa partnerom. Pošto atribut po definiciji meri „da li smo se ranije sreli“, svaka vrednost veća od nule pretvorena je u 1.

Starosni outlieri — zadržani

IQR pravilo označava 173 sloga kao outliere po godinama. Oni **nisu uklonjeni**. Za razliku od ocene 12 na skali 1–10, koja je očigledna greška, učesnik od 55 godina je validno zapažanje. Uklanjanje takvih slogova ne bi čistilo podatke nego bi ih sakatilo, a klasterovanje po starosti je legitiman mogući nalaz.

2.3 Obrada tekstualnog atributa `field`

Atribut `field` (oblast studija) je slobodan tekst sa **259 različitih vrednosti**, unetih potpuno nedosledno. Ilustrativni primeri iz podataka:

- razlike u veličini slova: Law (462), law (123), LAW (19) — tri zapisa iste oblasti;
- greške u kucanju: Finanace, Nutritiron, Speech Languahe Pathology, Intrernational Affairs, Computational Biochemsistry;
- skraćenice: Electrical Engg., MBA, SIPA, QMSS, TESOL;
- neinformativni odgovori: money, working, theory, GSAS;
- dvostruki smerovi: Law and English Literature [J.D./Ph.D.], Business/Law, Nutrition/Genetics.

Ostavljen takav, one-hot enkodiranje proizvelo bi 259 kolona, više nego svi ostali atributi zajedno.

Napisana je funkcija koja tekst svodi na mala slova i redom proverava prisustvo ključnih reči, svrstavajući vrednost u **11 širih oblasti plus Unknown**. Ključne reči su birane tako da hvataju i greške u kucanju (uz finance stoji i finanace, uz nutrition i nutritiron, uz engineer i engg).

Redosled provera je suštinski, ne slučajan

Obrazovanje se proverava prvo. Vrednosti math education i Art Education odnose se na ljude koji studiraju obrazovanje, a predmet je sporedan. Da se prvo proverava matematika, „nastavnik matematike” bio bi svrstan među matematičare.

Društvene nauke prethode umetnosti. Ključna reč lit (za literaturu) sadržana je u reči political . Da je redosled obrnut, politikologija bi bila svrstana u književnost. Postavljanjem društvenih nauka ispred, political science se ispravno hvata ranije.

Neki slučajevi su suštinski dvosmisleni i prihvaćeni su kao takvi: Theatre Management & Producing pada u Business/Finance zbog reči management , iako bi se moglo braniti i svrstavanje u umetnost. Takvih je malo i ne utiču na rezultate.

Rezultat grupisanja:

Grupa	Slogova	Grupa	Slogova
Business/Finance	2031	Engineering/Tech	610
Social Sciences	1836	Medicine/Health	581
Natural Sciences	877	Math/Statistics	196
Education	704	Journalism/Comm.	73
Law	685	Unknown	63
Arts/Humanities	673	Other	49

Samo **49 od 8378 slogova** (0.6%) ostalo je nesvrstano u kategoriji other , što potvrđuje da su ključne reči dovoljno obuhvatne.

2.4 Da li su nedostajuće vrednosti slučajne? (MNAR analiza)

Pre nego što se praznine popune, postavljeno je pitanje *zašto* vrednost nedostaje. Ako je učesnik ostavio ocenu partnera praznom, da li je to slučajno, ili znači da je sa sastankom nešto bilo?

Test je jednostavan: uporedi stopu poklapanja kada ocena nedostaje sa stopom kada je prisutna. Rezultat je upečatljiv:

Atribut	Nedostaje	Poklapanje kad NEDOSTAJE	Poklapanje kad POSTOJI
attractive_partner	202	0.015	0.168
attractive_o	212	0.014	0.169
intelligence_partner	296	0.034	0.170
sincere_partner	277	0.036	0.169
funny_partner	350	0.043	0.170
ambition_partner	712	0.110	0.170
shared_interests_partner	1067	0.112	0.172

Kada nedostaje ocena privlačnosti, stopa poklapanja pada sa 0.169 na **0.015** — jedanaest puta. Obrazac važi za sve ocene partnera, i pokazuje jasan **gradijent**: osobine koje se procenjuju u prvim sekundama (privlačnost, inteligencija) pokazuju najoštrij pad, dok osobine koje traže duži razgovor (ambicija, zajednička interesovanja)

pokazuju blaži.

Odluka: nalaz se ne pretvara u atribut

Bilo bi tehnički lako dodati indikatorsku kolonu „ovaj slog ima prazninu“. Ona bi bila snažno povezana sa ishodom i verovatno bi proizvela klaster sa vrlo niskom stopom poklapanja. Ali takav klaster ne bi bio *tip osobe*, bio bi grupa nepotpunih anketa. To opisuje kvalitet prikupljanja podataka, ne ljude. Nalaz je zato iskorišćen drugačije: usmerio je izbor metode imputacije (odeljak 2.9) i naknadnu proveru da nijedan dobijeni klaster nije artefakt imputacije.

2.5 Kategorijske praznine

Atributi `race` (63 praznine) i `race_o` (73) su kategorijski. Uobičajen postupak, popunjavanje najčešćom vrednošću, ovde je odbačen.

Razlog: najčešća vrednost je `En`. Popunjavanje bi tiho označilo 136 ljudi kao pripadnike te grupe. Svaka kasnija tvrdnja o rasnom sastavu nekog klastera bila bi delimično *naša konstrukcija*, a ne merenje. Umesto toga dodata je eksplicitna kategorija `Unknown` — nepoznato ostaje nepoznato.

Ista logika primenjena je i na `field`, gde 63 praznine takođe dobijaju `Unknown`.

2.6 Enkodiranje kategorijskih atributa

Algoritmi klasterovanja računaju rastojanja između brojeva, pa kategorije moraju biti binarizovane. Dve odluke zaslužuju obrazloženje.

Pol — jedna kolona umesto dve

One-hot enkodiranje pola dalo bi dve komplementarne kolone (`gender_male` i `gender_female`), koje nose *istu* informaciju. Problem nije redundantnost sama po sebi, nego njen efekat na rastojanje: dve kolone doprinose dvostruko većom razlikom nego jedna, pa bi pol dobio dvostruku težinu bez ikakvog razloga. Zadržana je jedna kolona `gender_male`.

Rasa, strukovna oblast — sve kategorije zadržane

2.7 Blok-normalizacija

Ovo je metodološki najvažnija odluka u celom preprocesiranju.

Standardizacija svake kolone na varijansu 1 deluje neutralno. Ali nije, jer se koncepti razlikuju po broju kolona koje ih kodiraju. Posle obične standardizacije, ukupna varijansa svakog koncepta jednaka je broju njegovih kolona:

Koncept	Kolona	Varijansa posle standardizacije
interesovanja	17	17
oblast studija	12	12
ocene partnera	6	6
demografija	3	3
pol	1	1

Posledica: hobiji bi dominirali rastojanjem **prosto zato što ih ima najviše**. Klasteri bi se skoro sigurno sveli na „ljudi koji vole sport naspram onih koji vole umetnost“, ali kao posledica aritmetike, ne strukture podataka.

Kategorijski atributi imali su suprotan problem. Neskalirane one-hot kolone imaju varijansu oko 0.05–0.25 (jer su uglavnom nule), pa su rasa i oblast studija zajedno doprinosili tek oko 5% ukupne varijanse, praktično su bili

nevidljivi za algoritam.

Odluka: 17 pojmovnih blokova, svaki skaliran na varijansu 1

Svi atributi su razvrstani u 17 blokova prema značenju, a zatim je svaki blok pomnožen faktorom koji njegovu *ukupnu* varijansu svodi na 1. Time svaki koncept — hobiji, preferencije, samoprocena, demografija, pol, rasa — nosi jednaku težinu, nezavisno od toga sa koliko je kolona kodiran.

Blokovi i njihove veličine:

Blok	Kol.	Blok	Kol.	Blok	Kol.
interests	17	partner_rating	6	met	1
field	12	rated_by_partner	6	interest_match	1
importance	6	demographics	3	gender	1
pref_o	6	same_values	2	samerace	1
self_rating	5	expectations	2	race	6
outcome	2	race_o	6	ukupno 83	

Posle normalizacije, svih 17 blokova ima varijansu tačno 1.000, a ukupna varijansa skupa je 17.00.

Vredi biti izričit oko posledice: jednokolonski blokovi poput `met`, `gender` ili `samerace` dobijaju istu težinu kao 17-kolonski blok interesovanja. To nije previd nego namera, težina pripada *konceptu*, ne broju kolona koje ga slučajno kodiraju. Da li je pol jednako važan kao svih sedamnaest hobija zajedno je pitanje na koje podaci ne odgovaraju; težina 1 po bloku je razumna, neutralna pretpostavka, ali jeste pretpostavka.

Poslednja tehnička napomena: varijanse blokova **ponovo se normalizuju posle imputacije**. Merenje pre toga bilo bi zavaravajuće, jer kNN privlači imputirane vrednosti ka lokalnom susedstvu i time smanjuje varijansu i to najviše u onim blokovima koji su imali najviše praznina.

2.8 Imputacija, korak 1: oporavak unutar iste osobe

Ključni uvid je da atributi poput `sports` ili `attractive` (samoprocena) nisu svojstva sastanka, oni su svojstva *osobe*, konstantna kroz svih njenih 5 do 22 reda. Ako jednom redu nedostaje `sports`, a petnaest drugih redova iste osobe beleži 9.0, nema šta da se procenjuje: vrednost je već poznata. Pozivati kNN da je „pogodi” bilo bi apsurdno.

Korak 1 zato popunjava praznine na nivou osobe iz njenih sopstvenih drugih redova — **tačan oporavak, bez procene**. Ovo je bilo moguće tek pošto je `person_id` rekonstruisan (odjeljak 1.3).

Šta je namerno isključeno

Atributi `pref_o *` opisuju šta *partner* traži, a partner se menja svakog reda. Popunjavanje medijanom po osobi dalo bi „medijanu preferenci svih koje sam upoznao” — što nije oporavak nego loša procena, gora nego ono što kNN može. Isto važi za ocene partnera i `age_o`. Oni su ostavljeni za korak 2.

Nalaz: korak 1 oporavlja samo 10 vrednosti

Očekivalo se da će oporavak unutar osobe rešiti znatan deo praznina. Umesto toga, od 3941 praznine na nivou osobe oporavljeno je svega **10**. Objašnjenje je i samo nalaz: praznine u atributima na nivou osobe su gotovo uvek „*sve ili ništa*” — učesnik je ili odgovorio na ceo blok pitanja, ili ga je preskočio u potpunosti, u kom slučaju nema odakle da se prepíše. Onih 79 učesnika koji su preskočili ceo blok interesovanja su tipičan primer.

2.9 Imputacija, korak 2: kNN

Ostaje 11585 vrednosti koje su istinski nepoznate: one koje učesnik nikada nije dao ni u jednom redu, i atributi na nivou sastanka (ocene partnera, `like`) koji se razlikuju od reda do reda i ne mogu se prepisati.


Korišćen je `KNNImputer` sa 5 suseda i težinama po rastojanju. Izbor metode direktno sledi iz MNAR nalaza (odjeljak 2.4): pošto praznine nisu slučajne, popunjavanje *jednom te istom* vrednošću (medijanom kolone) bilo bi posebno štetno. Svih 1067 praznina u `shared interests partner` dobilo bi identičnu vrednost, čime bi se stvorila veštačka, savršeno zbijena grupa nepotpunih slogova, a ta grupa bi imala i sistematski nižu stopu poklapanja. Klasterovanje bi je gotovo sigurno „otkrilo” kao tip osobe, iako je čist artefakt imputacije.

kNN umesto toga svaku prazninu popunjava iz pet najsličnijih slogova, pa je svaka vrednost prilagođena sopstvenom profilu. Provera potvrđuje da veštačkog grupisanja nema:

Atribut	Imputirano	Različitih vrednosti
shared_interests_partner	1067	1062
funny_o	360	358
like	240	236
attractive_partner	202	197
sports	79	77

Od 1067 imputiranih vrednosti, 1062 su različite. Imputacija medijanom dala bi **jednu**. Ovo je konkretan, merljiv dokaz da nijedan kasniji klaster ne može biti posledica imputacije.

Raspodele posle imputacije zadržavaju očekivan oblik, bez pikova koji bi ukazali na veštačko gomilanje:



Slika 1. Raspodele šest reprezentativnih atributa posle imputacije (skalirane jedinice). Nema izraženog pika na jednoj vrednosti, što bi bio znak imputacije konstantom.

2.10 Dva skupa i curenje informacije kroz imputaciju

Atributi `like` („koliko mi se partner svideo“) i `guess_prob_liked` („koliko mislim da se ja njemu svidih“) su bliski *proxy*-ji za odluku koja proizvodi `match`. Klasterovati sa njima, pa zatim izvestiti „ovaj klaster ima stopu poklapanja 30%“ bilo bi delimično cirkularno: klaster bi delom bio definisan upravo onim što se meri.

Zato su sačuvana dva skupa: pun (`x_scaled`, 83 atributa) i bez ishoda (`x_scaled_no_outcome`, 81 atribut). Skup bez ishoda je iskrena osnova za klasterovanje; pun skup je zadržan kao model za poređenje.

Suptilnost: curenje kroz susede pri imputaciji

Nije dovoljno imputirati jednom pa *zatim* izbaciti kolone ishoda. kNN bira susede koristeći **sve dostupne kolone** — uključujući `like`. Da je imputacija bila jedna, svih 11585 popunjenih vrednosti nosilo bi trag ishoda kroz izbor suseda, čak i pošto su kolone uklonjene. Zato su **dva skupa imputirana potpuno nezavisno**, sa dva odvojena `KNNImputer` objekta. Tek tako je osnova zaista čista.

Ovo je oblik zaštite od *data leakage*-a koji se lako previdi. Kao što će odeljak 3.6 pokazati, ispostavilo se da ishod ionako ne menja klastere ($ARI = 1.0$), pa opreznost nije bila neophodna — ali to se nije moglo znati unapred.

2.11 Izlazni fajlovi

Fajl	Oblik	Namena
X_scaled.csv	8378 × 83	svi atributi, ulaz za model poređenja
X_scaled_no_outcome.csv	8378 × 81	bez ishoda — glavni ulaz za klasterovanje
X_unscaled.csv	8378 × 83	originalne jedinice, za tumačenje centroida
metadata.csv	8378 × 4	wave, match, person_id, row_id
models/	—	skaler, oba imputera, konfiguracija

Fajl `X_unscaled.csv` sadrži imputirane podatke vraćene u originalne jedinice (inverzna transformacija skalera i blok-faktora). Bez njega bi centroidi klastera bili nizovi standardizovanih brojeva bez značenja; sa njim se može reći „ovaj tip ima prosečnu ocenu sporta 7.02“, što tek omogućava tumačenje.

Konfiguracija u `preprocessing_config.json` čuva definicije svih 17 blokova, faktore skaliranja, imena kolona ishoda i vrednost `random_state` — čime je ceo postupak potpuno rekonstruisan i ponovljiv.

3. Klasterovanje

3.1 Metodološki okvir

Pre prikaza rezultata, tri odluke koje važe za ceo ovaj deo.

Referentni algoritam

k-means je korišćen kao referentni model, a ostala četiri algoritma za validaciju i poređenje. Cela interpretacija, imenovanje tipova, čitanje centroida, analiza stopa poklapanja je građena na jednom modelu, dok ostali algoritmi odgovaraju na pitanje *da li je nađena struktura stvarna ili je artefakt k-means-a*.

Izbor broja klastera

Broj klastera biran je kombinacijom dve metode: **silhouette** koeficijenta i **elbow** metoda (SSE po k). Silhouette meri koliko je svaka tačka bliža svom klasteru nego najbližem susednom, vrednosti bliže 1 znače dobro razdvojene klastere, vrednosti oko 0 znače preklapanje. Elbow traži tačku u kojoj dodavanje novog klastera prestaje bitno da smanjuje grešku.

Kada se dve metode ne slažu, prednost je davana **interpretabilnosti** — rešenju čije se grupe mogu opisati i imenovati. Ovo je važno jer obe metrike, ako se prate slepo, vode ka rešenjima bez smisla.

Ishod izvan ulaza

Kroz sve modele korišćen je skup `x_scaled_no_outcome`. Atribut `match` nijednom nije bio ulaz. Time svaka kasnija tvrdnja o razlici u stopama poklapanja predstavlja **nezavisnu proveru**, a ne posledicu konstrukcije.

Sve nasumične operacije koriste `random_state = 42`, pa je svaki rezultat u ovom izveštaju tačno ponovljiv.

3.2 Skup 1: profil osobe

Prvi model koristi attribute koji opisuju samog učesnika: interesovanja, deklarisanе preferenci, samoprocene, pol, rasu, oblast studija, demografiju, stav o istoj rasi/religiji i očekivanja od događaja. Ukupno 54 atributa. Atributi partnera i susreta su izostavljeni, jer pitanje glasi „kakvi tipovi *ljudi* postoje", ne „kakvi tipovi susreta".

Prvi pokušaj: pol dominira

Silhouette po broju klastera:

k	2	3	4	5	6
silhouette	0.134	0.100	0.105	0.080	0.080

Najbolje rešenje je k = 2. Provera šta ta dva klastera znače dala je jednoznačan odgovor: ideo muškaraca po klasteru iznosi 0.999 i –1.001 (u standardizovanim jedinicama, dakle praktično „svi muškarci" i „sve žene"). **Najjača podela u podacima je pol.**

Stopa poklapanja u oba klastera je identična — 0.165 i 0.165. Podela je savršeno čvrsta, ali ne nosi nikakvu informaciju o ishodu. Očekivano, ali neupotrebljivo: da bi se saznalo nešto o tipovima ličnosti, mora se ići dublje.

Otkriveni artefakt u podacima

Pri ispitivanju rešenja sa k = 4 pojavio se mali klaster od **63 sloga**. Umesto da bude prihvaćen kao „redak tip ličnosti", proveren je: izračunata je razlika prosečnih vrednosti između tog klastera i ostatka, po svim atributima.

Atribut	Odstupanje od ostatka
race_Unknown	+4.73
field_Unknown	+3.34
d_age	+2.92
age	+0.66

Nalaz: lažni klaster

Klaster nije definisan nijednom osobinom ličnosti, već činjenicom da su za te slogove **rasa i oblast studija bile nepoznate**. Indikatori `Unknown`, uvedeni iz opreza pri obradi kategorijskih praznina (odjeljak 2.5), postali su najjači signal u prostoru i sami proizveli klaster. To nije struktura u podacima nego artefakt njihove pripreme. Kolone `Unknown` uklonjene su iz ovog skupa atributa, koji se sa 54 svodi na **52**.

Ovaj slučaj ilustruje širu pouku: klaster koji algoritam nađe nije automatski nalaz. Bez provere šta ga definiše, „grupa od 63 osobe sa posebnim profilom" ušla bi u izveštaj kao rezultat.

Klasterovanje unutar pola

Pošto pol dominira i zaklanja finiju strukturu, podaci su podeljeni po polu (4194 muškaraca, 4184 žena) i svaka grupa klasterovana zasebno. Iz skupa atributa dodatno su izbačeni pol i rasa: unutar jednog pola kolona pola je konstantna i samo dodaje šum, a cilj su tipovi definisani ličnošću, ne demografijom. Ostaje 46 atributa.

	k=2	k=3	k=4	k=5
Muškarci	0.071	0.075	0.071	0.082
Žene	0.103	0.093	0.091	0.077

Rezultat je asimetričan i sam po sebi zanimljiv. **Žene pokazuju jasan vrh na k = 2** — postoje dva prirodna tipa. **Muškarci nemaju vrh**: silhouette je ravan i nizak kroz sve vrednosti k, bez ijedne koja se izdvaja. Ne postoji prirodna potpodela muške grupe; ona je homogenija.

Doneta je odluka da se koriste **tri tipa**: jedna muška grupa (nepodeljena, jer podela nije opravdana) i dve ženske. Nametanje k = 2 i muškarcima proizvelo bi podelu koju podaci ne podržavaju.

Tumačenje tri tipa

Centroidi u originalnim jedinicama (izvod, poređeno sa ukupnim prosekom):

Atribut	C0 (M)	C1 (Ž)	C2 (Ž)	Prosek
age	26.63	26.90	24.98	26.40
sports	7.02	5.51	6.25	6.41
gaming	4.40	3.03	3.68	3.84
art	6.22	7.33	7.08	6.73
theater	6.09	7.31	7.79	6.79
exercise	6.04	6.11	6.94	6.23
attractive (samoprocena)	6.95	7.11	7.37	7.08
intelligence (samoprocena)	7.52	7.75	8.11	7.70
ambition (samoprocena)	7.53	7.38	8.02	7.58
attractive_important	26.90	16.85	19.99	22.49
ambtition_important	8.50	12.50	13.27	10.64
shared_interests_important	10.97	13.50	11.50	11.85

Imena su izvedena iz onoga po čemu se svaki tip najviše razlikuje od proseka:

- **C0 — Sport & looks-oriented (M), 4194 sloga.** Najviši na sportu (7.02) i gejmingu, najniži na svim kulturnim aktivnostima. Izgledu partnera daje 26.9 od 100 poena — najviše od svih tipova; ambiciji najmanje (8.5).
- **C1 — Culture & connection (Ž), 2572 sloga.** Visoke ocene umetnosti (7.33), muzeja, pozorišta i čitanja. Izgledu partnera daje najmanje (16.85), a zajedničkim interesovanjima najviše (13.50).
- **C2 — Confident & driven (Ž), 1612 slogova.** Najmlađe (24.98), sa najvišim samoprocenama u sve tri kategorije — privlačnost 7.37, inteligencija 8.11, ambicija 8.02 — i najaktivnije (vežbanje 6.94). Ambiciju partnera cene najviše (13.27).


Provera preko stope poklapanja

Tip	n	Stopa poklapanja
Sport & looks-oriented (M)	4194	0.165
Culture & connection (Ž)	2572	0.180
Confident & driven (Ž)	1612	0.140
ukupno	8378	0.165


Hi-kvadrat test nezavisnosti daje $\chi^2 = 11.64$, $p \approx 0.003$ — razlika je statistički značajna. Pošto ishod nikada nije bio ulaz, ovo je nezavisna potvrda da podela nije proizvoljna.

Zanimljiv je smer razlike: *Confident & driven* tip, sa najvišim samoprocenama, ima **najnižu** stopu poklapanja (0.140), dok *Culture & connection* ima najvišu (0.180). Moguće objašnjenje je veća selektivnost — visoko samopouzdanje može voditi strožem kriterijumu, a poklapanje zahteva obostrano interesovanje. Ovo je hipoteza koju podaci dopuštaju, ne uzročna tvrdnja koju dokazuju.

Vizuelizacija



Slika 2. Tri tipa u prostoru prve dve glavne komponente (PCA). Prve dve komponente objašnjavaju 22.6% ukupne varijanse.



Slika 3. Isti klasteri prikazani t-SNE metodom, na uzorku od 2000 slogova.

Obe projekcije pokazuju istu strukturu: pol razdvaja podatke duž glavne ose, dok su dva ženska tipa međusobno mekše razdvojena. Numerički rezultati to potvrđuju (vrednosti udela muškaraca po klasteru su praktično ± 1).

Opres pri čitanju ovakvih slika

PCA projekcija hvata samo 22.6% varijanse, pa preklapanje koje se vidi na ekranu *procenjuje* stvarno preklapanje u punom 52-dimenzionom prostoru. t-SNE, kao nelinearna metoda, čuva lokalna susedstva ali *ne* globalna rastojanja — razmaci između grupa na slici nemaju kvantitativno značenje i ne smeju se tumačiti kao mera razdvojenosti. Razdvojenost se procenjuje iz silhouette vrednosti, a slike služe kao ilustracija, ne kao dokaz.


3.3 Skup 2: preference i samoprocena

Drugi model koristi 11 atributa: šest deklariranih preferenci (`*_important`) i pet samoprocena. Pitanje je drugačije: *kako se ljudi grupišu po tome šta traže u partneru i kako vide sebe?*

Ovaj skup ima važnu osobinu — **nema jednu dominantnu osu poput pola**, pa je izabran kao teren za detaljno poređenje algoritama (odjeljak 3.4).

Izbor broja klastera

k	2	3	4	5	6
silhouette	0.143	0.142	0.084	0.087	0.104



Slika 4. Elbow kriva za skup preferenci. Lakat se jasno savija na $k = 3$.

Silhouette za $k = 2$ i $k = 3$ praktično je izjednačen (0.143 naspram 0.142), pa ta metrika ne razrešava izbor. Elbow kriva se, međutim, savija na $k = 3$. Izabrano je **$k = 3$** — metrike ga podržavaju jednako kao $k = 2$, a daje bogatiju i interpretabilniju podelu.

Tumačenje tri tipa

Atribut	C0	C1	C2	Prosek
attractive_important	44.09	19.32	17.87	22.49
sincere_important	9.31	20.02	18.15	17.40
intellicence_important	16.80	21.70	20.39	20.27
ambtition_important	5.58	8.66	13.57	10.64
shared_interests_important	7.09	12.75	12.73	11.85
attractive (samoprocena)	7.75	6.04	7.58	7.08
intelligence (samoprocena)	8.44	6.57	8.24	7.70
ambition (samoprocena)	7.98	6.13	8.43	7.58

- **C0 — Looks-driven, 1317 slogova.** Izgledu daje **44 od 100 poena** — gotovo polovinu ukupne težine, i dvostruko iznad proseka. Iskrenosti daje najmanje (9.31), ambiciji jedva 5.58. Uz to ima visoke samoprocene.
- **C1 — Character-seekers, 2852 sloga.** Najviše vrednuje iskrenost (20.02) i inteligenciju (21.70). Zanimljivo, ovaj tip ima *najniže* samoprocene u sve tri kategorije.
- **C2 — Ambition-valuers, 4209 slogova.** Najviša težina ambicije (13.57), uz visoke samoprocene, posebno ambicije (8.43).

Provera po polu pokazuje da grupe **nisu prerušen pol**: udeli muškaraca po klasterima su 0.48, 0.04 i -0.17 — mešovito, daleko od ± 1 koje bi ukazalo na podelu po polu.

Provera preko stope poklapanja

Tip	n	Stopa poklapanja
Looks-driven	1317	0.174
Character-seekers	2852	0.154
Ambition-valuers	4209	0.169

Hi-kvadrat daje $\chi^2 = 3.60$, $p \approx 0.17$ — razlika **nije statistički značajna**.

Numerički je *Looks-driven* najviši (0.174), a *Character-seekers* najniži (0.154), ali pri $p \approx 0.17$ toj razlici se ne može verovati — mogla bi biti posledica slučajnosti. Ovaj rezultat se izveštava kakav jeste: ono što ljudi *kažu* da traže ne razdvaja grupe po uspešnosti. To ne dokazuje da su preference nebitne, samo da se u ovom uzorku ne pojavljuje pouzdana veza.

Kontrast sa prethodnim modelom je informativan: tipovi zasnovani na tome *ko je osoba* razlikovali su se značajno ($p \approx 0.003$), dok se tipovi zasnovani na tome *šta traži* ne razlikuju.

3.4 Poređenje pet algoritama

Skup preferenci izabran je za detaljno poređenje jer nema dominantnu osu poput pola, pa različiti algoritmi imaju priliku da se stvarno razlikuju. Za svaki algoritam **ključni parametar je biran eksplicitno**, a ne uzet kao podrazumevana vrednost, jer izbor parametra često menja rezultat više nego izbor algoritma.

Broj klastera je svuda fiksiran na $k = 3$, izabran ranije za ovaj skup, kako bi poređenje bilo pošteno: isti zadatak, različit metod. Izuzetak je DBSCAN, koji broj klastera određuje sam.

Hijerarhijsko klasterovanje (agglomerative)


Algoritam počinje sa svakom tačkom kao zasebnim klasterom i uzastopno spaja dva najbliža. Ključni parametar je **linkage** — način merenja rastojanja između klastera: `ward` (minimizuje unutarklastersku varijansu), `complete` (najudaljeniji par) ili `average` (prosečno rastojanje).

linkage	silhouette	Veličine klastera
ward	0.131	4671 / 2705 / 1002
complete	0.231	7763 / 307 / 308
average	0.368	8343 / 19 / 16

Zašto je izabran ward iako ima najnižu metriku

Po silhouette vrednosti `average` ubedljivo pobeđuje (0.368 naspram 0.131). Ali veličine klastera otkrivaju šta se zapravo desilo: `average` je izdvojio **35 outliera** u dva sićušna klastera, a svih preostalih 8343 sloga strpao u jedan. To nije podela podataka nego „svi zajedno plus nekoliko čudaka”. Silhouette je visok upravo zato što je tih 35 tačaka izuzetno zbijeno i daleko od ostatka. Isti obrazac, blaži, važi za `complete`.

`ward` daje jedinu uravnoteženu podelu (4671 / 2705 / 1002), uporedivu sa k-means rešenjem. Izabran je **ward** — interpretabilnost je pretpostavljena metrici koju je naduvala degenerisana podela.



Slika 5. Dendrogram (ward, uzorak od 300 tačaka, prikazano prvih 5 nivoa). Vertikalna osa pokazuje rastojanje pri spajanju; presecanjem na odgovarajućoj visini dobija se željeni broj klastera.


Gaussian Mixture (GMM)

GMM modeluje podatke kao mešavinu Gausovih komponenti, sa *mekim* pripadanjem, svaka tačka ima verovatnoću pripadnosti svakoj komponenti. Ključni parametar je **tip kovarijanse**, koji određuje oblik komponenti. Biran je Bajesovim informacionim kriterijumom (BIC), koji nagrađuje kvalitet uklapanja a kažnjava složenost; niže je bolje.

covariance_type	spherical	diag	tied	full
BIC (k = 3)	88240	80150	51875	-24331

Izbor je nedvosmislen: `full` je jedina negativna vrednost i drastično niža od ostalih. Svaka komponenta dobija svoj neograničen eliptični oblik.

Dodatno je ispitano kako BIC zavisi od broja komponenti, što je za GMM analogon elbow metoda:



Slika 6. BIC po broju komponenti (kovarijansa `full`). Kriva se oštro savija na $k = 3$ i potom poravnava.

k	1	2	3	4	5	6
BIC	56583	-8967	-24331	-27388	-29697	-31422

Pad od $k = 1$ do $k = 3$ je strm (preko 80000), a posle $k = 3$ se naglo usporava (svega 3000 po koraku). Lakat je na $k = 3$. To je nezavisna, treća potvrda izbora — pored silhouette i elbow metoda, i BIC ukazuje na tri grupe.

BIRCH

BIRCH gradi stablo sažetaka klastera i pogodan je za velike skupove. Ključni parametar je **threshold** — poluprečnik unutar kojeg se tačke spajaju u isti podklaster. Ispitan je širok raspon vrednosti, uz praćenje i silhouette i *balansa* (odnos najmanjeg i najvećeg klastera; vrednost bliža 1 znači ravnomerniju podelu):

threshold	silhouette	balans	Veličine klastera
0.1	0.141	0.13	2907 / 647 / 4824
0.2	0.091	0.54	2002 / 2643 / 3733
0.3	0.094	0.12	3883 / 4024 / 471
0.4	0.111	0.10	5348 / 522 / 2508
0.5	0.179	0.12	6687 / 884 / 807
0.7	0.065	0.20	3164 / 853 / 4361
1.0	0.139	0.10	1729 / 6060 / 589
1.5	0.208	0.02	787 / 136 / 7455


Obrazac je isti kao kod hijerarhijskog: **viši silhouette prati lošiji balans**. Pri threshold = 1.5 metrika je najviša (0.208), ali jedan klaster drži 7455 od 8378 tačaka — degeneracija. Izabran je **threshold = 0.2**, jedina vrednost sa pristojnim balansom (0.54), dakle jedina koja daje stvarnu trodelnu podelu.

Vrednost threshold = 2.0 je testirana, ali BIRCH pri njoj nalazi samo jedan podklaster i ne može da formira tri klastera, pa je izostavljena.

DBSCAN

DBSCAN grupiše tačke u oblastima visoke gustine, a ostale označava kao šum. Za razliku od prethodnih, **ne prima broj klastera**, određuje ga sam. Ima dva parametra: `eps` (poluprečnik susedstva) i `min_samples` (broj tačaka potreban za gusto područje).

Standardni postupak za izbor `eps` je **k-distance graf**: za svaku tačku izračuna se rastojanje do njenog k-tog najbližeg suseda, rastojanja se sortiraju i traži „lakat“ u kojem naglo raste. Taj lakat označava prirodnu granicu gustine. Umesto da se `min samples` fiksira napamet, ispitane su četiri vrednosti:



Slika 7. k-distance krive za četiri vrednosti `min_samples`. Ni jedna nema oštar lakat.

Grafik objašnjava zašto DBSCAN ovde ne može da radi. Za male vrednosti `min_samples` (5 i 10), **velika većina tačaka ima rastojanje približno 0** do svog k-tog suseda — kriva leži na nuli pa naglo skače tek na samom kraju. Uzrok je priroda podataka: skup preferenci ima 11 atributa, od kojih su mnogi diskretne skale, pa veliki broj učesnika ima *identične* odgovore. Za veće vrednosti (20 i 50) kriva je glatka i raste postupno, opet bez oštrog lakta.

Pošto grafik ne daje prirodnu vrednost, ispitana je mreža od devet kombinacija:

<code>min_samples</code>	<code>eps</code>	Klastera	Šum	Najveći klaster
5	0.5	436	8	1455
5	1.0	105	0	6676
5	1.5	10	0	8203
10	0.5	377	459	1439
10	1.0	94	81	6676
10	1.5	9	9	8203
20	0.5	128	4099	1375
20	1.0	32	961	6676
20	1.5	4	78	8203

Zaključak: DBSCAN nije pogodan za ove podatke


Nijedna kombinacija ne daje smislenu podelu. Male vrednosti `eps` rasparčavaju podatke na stotine klastera (do 436), velike ih spajaju u jedan džinovski (8203 od 8378 pri `eps` = 1.5). Ne postoji vrednost između koja bi dala nekoliko uravnoteženih grupa. Ovo potvrđuje ono što je k-distance grafik nagovestio: podaci su **jednoliki gusti**, bez praznina između grupa koje bi DBSCAN mogao da iskoristi. Problem je u strukturi podataka, ne u izboru parametara.

Zbirno poređenje

Svih pet algoritama, sa izabranim parametrima:

Algoritam	Parametar	silhouette	ARI vs k-means	Klastera
k-means	k = 3	0.142	1.000	3
Hijerarhijsko	linkage = ward	0.131	0.569	3
GMM	covariance = full	0.030	0.080	3
BIRCH	threshold = 0.2	0.091	0.421	3
DBSCAN	eps = 1.0, min_samples = 10	0.074	0.152	94

ARI (Adjusted Rand Index) meri slaganje dve podele: 1.0 znači identične, 0 znači slaganje na nivou slučajnosti.



Slika 8. Istih 8378 tačaka, ista PCA projekcija, obojena prema podeli svakog od pet algoritama.

Slika i tabela zajedno pričaju istu priču:

- **k-means i hijerarhijsko** daju istu grubu strukturu — tri prepoznatljive oblasti, sa razlikama samo u položaju granica. Slaganje je umereno (ARI 0.569), što je najviše od svih parova.
- **GMM potpuno promašuje.** Na slici su boje temeljno izmešane, bez koherentnih oblasti; silhouette je blizu nule (0.030), a ARI 0.080 — praktično nikakvo slaganje. Uzrok je što skup preferenci nema Gausovu strukturu, pa nametanje eliptičnih komponenti ne daje smislen rezultat, bez obzira što je parametar kovarijanse pažljivo biran.
- **BIRCH** zadržava grubu trodelnu strukturu ali pomera granice (ARI 0.421).
- **DBSCAN** je na slici gotovo jednobojan sa razbacanim tačkicama — njegova 94 „klastera” su jedna dominantna grupa plus sitne krhotine.

Metodološka pouka: silhouette se ne čita izolovano

Kroz ceo ovaj odeljak ponavlja se isti obrazac. Kod hijerarhijskog, average ima najviši silhouette (0.368) uz podelu 8343/19/16. Kod BIRCH-a, threshold = 1.5 ima najviši silhouette (0.208) uz podelu 787/136/7455. U oba slučaja visoka vrednost dolazi od izdvajanja šačice outliera, ne od uspešne podele. **Silhouette mora da se čita zajedno sa veličinama klastera**; sam po sebi može da nagradi upravo ono što je najgore.


Konačno: nijedan algoritam nije našao bitno bolju podelu od k-means-a. To opravdava njegov izbor za referentni model na kojem je građeno tumačenje.

3.5 Skup 3: interesovanja

Treći model koristi samo 17 atributa o hobijima. Pitanje je najuže i najčistije: *da li se ljudi grupišu po tome kako provode slobodno vreme, nezavisno od pola i od onoga što traže u partneru?*

Izbor broja klastera

	k	2	3	4	5	6
silhouette		0.147	0.099	0.092	0.093	0.084



Slika 9. Elbow kriva za skup interesovanja. Lakat i vrh silhouette vrednosti poklapaju se na $k = 2$.

Za razliku od prethodnih skupova gde su metrike bile bliske, ovde je izbor jednoznačan: silhouette ima jasan vrh na $k = 2$ (0.147, znatno iznad ostalih), a elbow se savija na istom mestu. Obe metode se slažu.

Dva tipa životnog stila


Hobi	C0	C1	Prosek	Hobi	C0	C1	Prosek
sports	7.09	5.88	6.41	art	4.98	8.09	6.73
tvsports	4.97	4.25	4.57	museums	5.47	8.18	6.99
exercise	6.35	6.14	6.23	theater	5.26	7.98	6.79
gaming	3.84	3.84	3.84	concerts	5.57	7.82	6.83
tv	4.86	5.66	5.31	yoga	3.15	5.29	4.35

- **C0 — Sporty/casual, 3671 slog.** Viši na sportu (7.09), niži na svim kulturnim aktivnostima.
- **C1 — Cultural/arts, 4707 slogova.** Znatno viši na umetnosti (8.09), muzejima (8.18), pozorištu (7.98), koncertima (7.82) i jogi.

Ključni nalaz: podela prelazi pol

Udeo muškaraca po klasteru iznosi 0.35 i -0.27 — daleko od ± 1 koje je viđeno kod profila osobe. Izraženo u procentima: *Sporty/casual* je 68% muški i 32% ženski, *Cultural/arts* je 36% muški i 64% ženski. Obe grupe sadrže i muškarce i žene u znatnom broju. Interesovanja, dakle, grupišu ljude **po životnom stilu, ne po polu** — što je potpuno drugačija struktura od one koju je dao prvi model nad istim ljudima.

Tumačenje glavnih komponenti



Slika 10. Dva tipa u prostoru prve dve glavne komponente. Podela prati PC1 gotovo savršeno.

Da bi se razumelo šta ose na slici znače, ispitani su doprinosi pojedinačnih hobija svakoj komponenti (PCA loadings):

Komponenta	Udeo varijanse	Najjači pozitivni doprinosi	Najjači negativni
PC1	23.3%	museums 0.39, art 0.39, theater 0.38, concerts 0.33	sports -0.12
PC2	12.1%	tvsports 0.52, sports 0.46, gaming 0.36, exercise 0.33	reading -0.22

Interpretacija je jasna: **PC1 je osa kultura-sport**, i klasteri se dele upravo duž nje. To znači da slika nije proizvoljna projekcija — glavna osa varijacije u podacima jeste ona po kojoj se grupe razdvajaju. **PC2 razdvaja fizički aktivne od mirnijih** (sport i gejming naspram čitanja).

Napomena o znaku: PCA bira *pravac* ose, ali je smer (koji kraj je pozitivan) matematički proizvoljan. Bitno je šta osa razdvaja, ne koji je kraj pozitivan.

Provera preko stope poklapanja

Tip	n	Stopa poklapanja
Sporty/casual	3671	0.153
Cultural/arts	4707	0.174

Hi-kvadrat daje $\chi^2 = 5.98$, $p \approx 0.015$ — razlika je značajna. Kulturni tip nešto češće ostvaruje poklapanje.

Replikacija poređenja algoritama

Poređenje algoritama sprovedeno je na skupu preferenci. Da bi se proverilo da zaključci nisu specifični za taj skup, isto poređenje je ponovljeno ovde. Geometrija je bitno drugačija: 17 kontinualnih dimenzija hobija naspram 11 diskretnih skala preferenci. Parametri osetljivi na geometriju (tip kovarijanse GMM-a, prag BIRCH-a) **ponovo su birani za ovaj skup**, a ne preneti.

Algoritam	silhouette	ARI vs k-means	Klastera
k-means	0.147	1.000	2
Hijerarhijsko (ward)	0.121	0.559	2
GMM (covariance = full)	0.108	0.428	2
BIRCH (threshold = 0.3)	0.109	0.459	2

DBSCAN je ovde izostavljen: njegovo ponašanje je iscrpno utvrđeno na skupu preferenci (k-distance analiza i puna mreža parametara), gde je degenerisao bez obzira na podešavanja. Ponavljanje ne bi dodalo nov nalaz.


Nalaz: skup atributa određuje i koji algoritmi mogu da rade

k-means i hijerarhijsko slažu se gotovo isto kao na prethodnom skupu (ARI 0.559 ovde, 0.569 tamo) — njihovo slaganje je **stabilno svojstvo podataka**, ne posebnost jednog skupa.

Informativan je kontrast kod GMM-a i BIRCH-a. Na preferencama su oba slabo prošla — GMM je pao na silhouette 0.030 uz ARI 0.080. Na interesovanjima se **oporavljaju**: GMM postiže 0.108 (ARI 0.428), BIRCH 0.109 (ARI 0.459), i oba reprodukuju u suštini istu podelu kao k-means. Razlog je verovatno geometrijski: interesovanja su 17 kontinualnih, ravnomerno raspoređenih dimenzija, bližih glatkoj strukturi koju ti algoritmi pretpostavljaju, dok su skale preferenci diskretne i grupisanije. Slab učinak GMM-a ranije bio je, dakle, specifičan za geometriju tog skupa.

Treći tip pri k = 3

Iako metrike podržavaju k = 2, ispitano je i rešenje sa tri klastera — da bi se videlo da li se pojavljuje dodatni smislen tip.



Slika 11. Ista PCA projekcija, obojena prema k = 2 (levo) i k = 3 (desno). Vidi se odakle se treći tip izdvaja.

Hobi	C0	C1	C2	Prosek
sports	7.32	4.48	7.59	6.41
tvsports	4.99	2.47	6.61	4.57
art	4.88	7.93	7.70	6.73
theater	4.98	7.93	7.80	6.79
clubbing	5.19	5.67	6.60	5.75
dining	6.80	8.23	8.53	7.78
concerts	5.42	7.38	8.04	6.83
movies	6.83	8.52	8.66	7.93
music	6.96	8.20	8.63	7.86

Pojavljuje se treći tip koji nije „između” prva dva, nego ima *sopstveni* identitet:

- **C0 — Sports-focused, 3129 slogova** (poklapanje 0.159)
- **C1 — Culture-focused, 2908 slogova** (0.164) — najniži na sportu (4.48) i TV sportu (2.47)
- **C2 — Socially active, 2341 slog** (0.173) — najviši na *izlaznim* aktivnostima: izlasci, večere, koncerti, filmovi, muzika. Uz to je visok i na sportu (7.59) i na kulturi (7.70) — ovo nisu ljudi koji biraju između sporta i kulture, nego oni koji izlaze.

Hi-kvadrat za trodelnu podelu daje $\chi^2 = 2.02$, $p = 0.36$ — razlika u stopi poklapanja **nije značajna**. Redosled (0.159 → 0.164 → 0.173) je zanimljiv i moglo bi se pretpostaviti da lagodnost u društvenim situacijama pomaže na ovakvom događaju, ali je to najviše slaba tendencija, ne pouzdana razlika.

Koliko su tipovi zaista rodno neutralni

Udeli po tipu ($k = 2$) su 68% / 32% i 36% / 64% — mešovito, ali sa nagibom. Odakle nagib?

Naginju ženama	Razlika	Naginju muškarcima	Razlika
shopping	-1.71	sports	+1.23
theater	-1.41	gaming	+1.12
yoga	-1.28	tvsports	+0.84

Nagib potiče od svega nekoliko snažno rodno vezanih hobija. Većina ostalih aktivnosti — večere, filmovi, muzika, čitanje — praktično je rodno neutralna, i upravo zato se klasteri mešaju umesto da se čisto podele po polu.

Veza interesovanja i preferenci

Postoje sada dve nezavisne podele istih ljudi: po hobijima i po tome šta traže u partneru. Da li su povezane? Unakrsna tabela (procenti unutar svakog tipa interesovanja):

Tip interesovanja	Ambition-valuers	Character-seekers	Looks-driven
Cultural/arts	58.3%	30.3%	11.4%
Sporty/casual	39.9%	38.8%	21.2%

Hi-kvadrat test nezavisnosti daje $\chi^2 = 308.14$, $p < 0.001$ — podele su snažno povezane, daleko od nezavisnih.

Konkretno: kulturno orijentisani ljudi **upola ređe** daju prioritet izgledu (11.4% naspram 21.2%) i znatno češće cene ambiciju (58.3% naspram 39.9%). Životni stil i partnerski prioriteti idu zajedno.

3.6 Skup 4: pun skup atributa

Poslednji model koristi svih 83 atributa, uključujući ocene partnera i proxy-je ishoda. Motivacija je bila jednostavna radoznalost: šta se dešava ako se ništa ne izostavi?

Silhouette po k daje blag vrh na $k = 3$ (0.087), pa je izabrana ta vrednost.

Pretpostavka koja se pokazala pogrešnom

Očekivanje je bilo da će proxy-ji ishoda, kao najinformativniji atributi, preoblikovati klastera i verovatno ih zdominirati. Da bi se to proverilo, ista podela je izračunata i na skupu bez ishoda, pa upoređena.

ARI = 1.000

Podele su **identične** — dodavanje atributa `like` i `guess_prob_liked` ne menja nijednu dodelu. Struktura je već bila određena ostalim atributima, a proxy-ji ishoda su se „provezli“ ne pomerivši nijednu tačku. Pretpostavka je bila pogrešna, i to je korisna opomena da se pretpostavke proveravaju naspram podataka umesto da im se veruje.

Šta pun skup zapravo nalazi

Podela na tri klastera: 361 / 4024 / 3993 slogova. Udeli muškaraca: -0.06, 1.00, -1.00. Dva velika klastera su, dakle, opet **pol** — čak i sa svim atributima, pol ostaje dominantna osa. Ali treći, mali klaster je *rodno neutralan* (-0.06) i ima stopu poklapanja **0.39**, više nego dvostruko iznad ukupnih 0.165.

Poređenje tog malog klastera sa ostatkom:

Atribut	Mali klaster	Ostatak	Razlika
met	1.00	0.00	+1.00
shared_interests_partner	6.89	5.43	+1.46
funny_partner	7.70	6.35	+1.35
attractive_o	7.16	6.14	+1.01
attractive_partner	7.14	6.15	+0.99
age	25.26	26.45	-1.19

Razlika kod `met` je tačno 1.00 — savršena podela. Provera raspodele: **359 od 361 sloga ima `met` = 1**, a dva izuzetka (0.47 i 0.51) su slogovi u kojima je ta vrednost nedostajala pa je imputirana.

Nalaz: jedan binarni atribut formira sopstveni klaster

Klaster nije tip ličnosti — čine ga **parovi koji su se poznavali pre događaja**. Oni se međusobno ocenjuju više na svakoj osobini i ostvaruju poklapanje u 39% slučajeva, naspram 16.5% ukupno. Objašnjenje je prozaično: ljudi koji se već znaju imaju ogromnu prednost na četvorominutnom susretu — veza već postoji. Zanimljivo je da je jedan jedini binarni atribut, `met`, dovoljno informativan da sam formira klaster, i da to postaje vidljivo tek kada se on uvede u model.

Kako se pun i redukovan skup daju identične klastere, proxy-ji ishoda nisu doprineli strukturi. To retrospektivno opravdava njihovo izostavljanje iz glavnih modela: nisu bili potrebni, a njihovo izbacivanje je sačuvalo `match` kao nezavisnu proveru.

4. Tumačenje i zaključci

4.1 Šta su klasteri otkrili

Klasterovanje istih 8378 učesnika pod četiri različita skupa atributa proizvelo je **suštinski različite strukture**. *Izbor atributa je bio važniji od izbora algoritma*. Ista populacija grupisala se potpuno drugačije — po polu, po životnom stilu ili po vrednostima — u zavisnosti od toga šta je algoritmu dato na uvid.

Skup atributa	Struktura koju nalazi	χ^2	p	Značajno
Profil osobe (52)	pol, potom tri tipa ličnosti	11.64	0.003	da
Interesovanja (17)	životni stil, prelazi pol	5.98	0.015	da
Preference (11)	šta se traži u partneru	3.60	0.17	ne
Pun skup (83)	pol + prethodno poznanstvo	—	—	—

Pojedinačni nalazi:

- **Profil osobe** deli se prvo po polu; tek klasterovanjem unutar pola pojavljuju se tri tipa (jedan muški, dva ženska). Oni se značajno razlikuju po stopi poklapanja, pri čemu samopouzdana, ambiciozni ženski tip ima najnižu (0.140), a kulturno orijentisani najvišu (0.180).
- **Interesovanja** daju podelu koja *prelazi pol*: sportski i kulturni tip sadrže i muškarce i žene (68/32 i 36/64). Pri $k = 3$ pojavljuje se i treći, društveno aktivan tip. Razlika u poklapanju je značajna za $k = 2$, ali ne i za $k = 3$.
- **Preference** daju tri jasna tipa (izgled / karakter / ambicija), ali se oni *ne* razlikuju značajno po uspešnosti.
- **Pun skup** otkriva da atribut `met` sam formira klaster sa dvostrukom stopom poklapanja, i da proxy-ji ishoda ne menjaju strukturu (ARI = 1.0).

Interesovanja i preference nisu nezavisni ($\chi^2 = 308$, $p < 0.001$): kulturno orijentisani ljudi upola ređe daju prioritet izgledu. Skupovi atributa, dakle, hvataju povezane ali različite aspekte istih ljudi.

Najjasniji suštinski nalaz

Dva modela zasnovana na tome **ko je osoba**, profil i životni stil, daju grupe koje se značajno razlikuju po uspešnosti upoznavanja. Model zasnovan na tome **šta osoba kaže da traži** ne daje takvu razliku. U ovom uzorku, dakle, uspešnost je povezana sa osobinama koje se mogu opaziti, a ne sa deklariranim prioritetima. Ovo je asocijacija unutar posmatranih klastera, ne dokaz uzročnosti, i ne znači da su preference nebitne za bilo kog pojedinca, samo da se pouzdana veza u ovim podacima ne pojavljuje.

4.2 Metodološke pouke

Nekoliko zapažanja koja se ponavljaju kroz rad i imaju širu vrednost od ovog konkretnog skupa.

Metrika se ne čita izolovano

Silhouette je više puta nagradio degenerisane podele. Kod hijerarhijskog klasterovanja, `average` linkage postiže 0.368 tako što izdvoji 35 outliera i sve ostalo strpa u jedan klaster. Kod BIRCH-a, prag 1.5 postiže 0.208 uz klaster od 7455 tačaka. U oba slučaja najviša metrika označava najgore rešenje. Silhouette mora da se čita zajedno sa veličinama klastera i sa proverom da li se grupe uopšte mogu opisati.

Klaster nije nalaz dok se ne proveri šta ga definiše

Mali klaster od 63 sloga izgledao je kao redak tip ličnosti. Provera je pokazala da ga definišu indikatori `known`.

— dakle nedostajući podaci, ne osobine. Bez te provere, artefakt pripreme podataka ušao bi u izveštaj kao rezultat.

Curenje informacije može biti suptilno

Izbacivanje kolona ishoda *posle* imputacije ne bi bilo dovoljno, jer kNN bira susede koristeći sve dostupne kolone. Dve nezavisne imputacije bile su neophodne da bi osnova zaista bila čista. To što se na kraju pokazalo da ishod ionako ne menja klaster ne obesmišljava opreznost, to se nije moglo znati unapred.

Uspeh algoritma zavisi od podudaranja pretpostavki sa podacima

GMM je na skupu preferenci potpuno promašio (silhouette 0.030), a na skupu interesovanja radio sasvim pristojno (0.108, ARI 0.428) — isti algoritam, ista pažnja pri izboru parametara, suprotni ishodi. Razlika je u geometriji podataka. DBSCAN, pak, nije radio ni na jednom skupu, jer podaci nemaju gustinske praznine koje su njegov osnovni princip. Ne postoji „najbolji“ algoritam nezavisno od podataka.

Težina koncepta nije isto što i broj kolona

Bez blok-normalizacije, sedamnaest hobija bi zdominiralo rastojanje nad jednom kolonom pola prosto aritmetikom, a rasa i oblast studija bili bi praktično nevidljivi. Ova odluka je verovatno najviše uticala na to kakvi su klasteri uopšte mogli da nastanu.

4.3 Ograničenja

Nekoliko ograda koje treba imati u vidu pri čitanju rezultata.

- **Jedinica posmatranja.** Klasterovani su sastanci, ne osobe, pa učesnici sa više sastanaka nose veću težinu. Podela na tipove ličnosti time je blago pristrasna ka onima koji su imali više susreta.
- **Rekonstruisani identitet.** Atribut `person_id` je heuristika. Provera nije našla nedoslednosti, ali dvoje učesnika sa identičnom demografijom i preferencama u istom talasu bili bi spojeni.
- **Slaba struktura.** Silhouette vrednosti su svuda niske (0.10–0.15), što znači da se klasteri znatno preklapaju. Tipovi su meki, a ne oštro odvojene grupe; granice između njih su donekle proizvoljne.
- **Uzorak.** Podaci potiču sa jednog univerziteta, iz specifičnog konteksta brzih sastanaka početkom 2000-ih. Nalazi se ne mogu uopštavati na širu populaciju.
- **Asocijacija, ne uzročnost.** Razlike u stopama poklapanja pokazuju povezanost, ne uzrok. Tumačenja ponuđena uz njih (npr. da veće samopouzdanje vodi većoj selektivnosti) su hipoteze koje podaci dopuštaju, ne zaključci koje dokazuju.
- **Težina blokova.** Odluka da svaki koncept nosi varijansu 1 je razumna, ali jeste izbor. Drugačija raspodela težina dala bi drugačije klastere.

Uz ove ograde, rezultati čine koherentnu celinu: četiri različita pogleda na istu populaciju, svaki sa sopstvenom strukturom, i jedan dosledan nalaz o tome koje vrste atributa se povezuju sa ishodom, a koje ne.